

02. System moderacji treści w sieci społecznościowej z warstwową decyzją

Wyobraź sobie platformę społecznościową, w której każdy post i komentarz podlega nie tylko automatycznej ocenie przez inteligentny model językowy, ale też reakcjom społeczności. Użytkownicy mogą zgłaszać treści, a ich reputacja wpływa na siłę tych zgłoszeń. Każda publikacja jest oceniana w kontekście reputacji autora, historii jego aktywności i charakteru zgłoszeń. To decyduje, czy treść pozostaje widoczna, zostaje oznaczona ostrzeżeniem, wymaga manualnej weryfikacji, czy zostaje ukryta. System działa asynchronicznie, zapisując wszystkie decyzje i odwołania, tworząc dynamiczny proces, w którym ryzyko publikacji jest stale wyważane między automatyczną oceną, interakcją społeczności a polityką platformy. Każdy przypadek jest audytowalny i przewidywalny w czasie.

1. Jako użytkownik chcę opublikować post, aby podzielić się treścią z innymi.

2. Jako użytkownik chcę skomentować post, aby wziąć udział w dyskusji.

- możliwość hierarchicznego powiązania komentarza z postem.

3. Jako użytkownik chcę widzieć status moderacyjny swojej treści.

- prezentacja aktualnego statusu (PENDING, PUBLISHED, FLAGGED, REVIEW, REJECTED); automatyczne odświeżanie stanu po zmianie. status musi być spójny w czasie (eventual consistency dopuszczalna, ale UI pokazuje ostatnią znaną wartość).

4. Jako użytkownik chcę otrzymać informację o zmianie statusu mojej treści wraz z uzasadnieniem.

- Powiadomienie użytkownika o każdej zmianie statusu; zapis uzasadnienia decyzji w historii zdarzeń.
- Powiadomienie powinno docierać w ciągu kilku sekund po zmianie; wszystkie powiadomienia muszą być audytowalne.

5. Jako użytkownik chcę zgłosić cudzą treść jako naruszającą zasady, podając powód zgłoszenia.

- Możliwość tworzenia zgłoszenia; powiązanie zgłoszenia z treścią i użytkownikiem; opcjonalny komentarz.